

Inteligência Artificial: Uma Abordagem de Aprendizado de Máquina

Análise de Componentes Principais

Prof. Tiago A. Almeida


Motivação

- Aplicação para compressão de dados
 - Redução de espaço
 - economia de espaço para armazenamento
 - redução de tempo para transmissão
 - redução da influência de ruídos ou *outliers*
 - **visualização dos dados (3D, 2D)**
 - **aceleração do aprendizado dos algoritmos de AM**

Compressão de dados

Exemplo


- Redundância nos dados
 - Muito comum na prática
 - Dados coletados de diferentes fontes (ex: Internet)
 - Elevado número de atributos
 - Difícil detecção manual



Compressão de dados


Exemplo

- Redundância nos dados
 - Muito comum na prática
 - Dados coletados de diferentes fontes (ex: Internet)
 - Elevado número de atributos
 - Difícil detecção manual
- Um dos eixos pode ser removido
- $2D \rightarrow 1D$




Compressão de dados

2D → 1D



Compressão de dados

2D → 1D




Projeção
dos dados na linha
vermelha




Compressão de dados

2D → 1D



Compressão de dados

2D → 1D




$$\begin{aligned}x^{(1)} \in \mathbb{R}^2 &\rightarrow z^{(1)} \in \mathbb{R} \\x^{(2)} \in \mathbb{R}^2 &\rightarrow z^{(2)} \in \mathbb{R} \\&\vdots \\x^{(m)} \in \mathbb{R}^2 &\rightarrow z^{(m)} \in \mathbb{R}\end{aligned}$$

Novo atributo z que
representa (uma
aproximação) x_1 e x_2




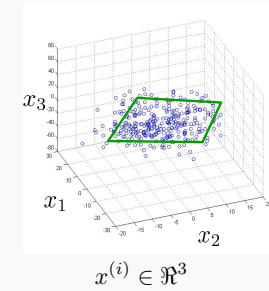
Compressão de dados

3D → 2D



Compressão de dados

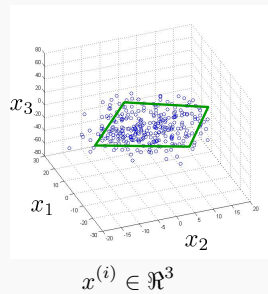
3D → 2D



Dados originais são projetados no plano



Compressão de dados

3D → 2D



Compressão de dados

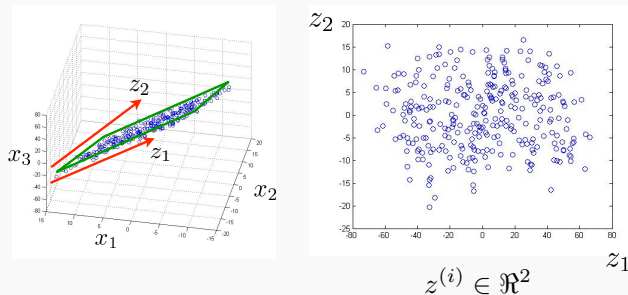
3D → 2D



Dados originais são projetados no plano

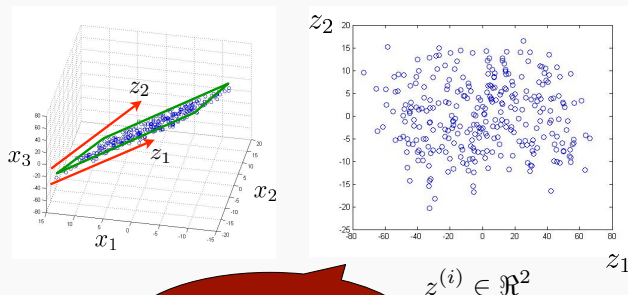
Compressão de dados

3D → 2D



Compressão de dados

3D → 2D




Aplicações reais:
1000D → 100D

Visualização de dados

- Aplicações reais normalmente trabalham com bases de dados com muitas amostras formadas por muitos atributos. Ex: $X \in \mathbb{R}^{100}$
 - É impossível visualizar os dados no formato original
- Muitas vezes a visualização dos dados auxilia na escolha dos métodos e na detecção de *outliers*
 - Deseja-se reduzir as dimensões para plotar

Visualização de dados

- Mapeamento de $X \in \mathbb{R}^{100} \rightarrow Z \in \mathbb{R}^2$




Inteligência Artificial: Uma Abordagem de Aprendizado de Máquina

Análise de Componentes Principais Método


Análise de componentes principais: Ideia

- Seja a base de dados $\mathbf{X} = [x_1, x_2]$
- Deseja-se reduzir de 2D \rightarrow 1D




Análise de componentes principais: Ideia

- Seja a base de dados $\mathbf{X} = [x_1, x_2]$
- Deseja-se reduzir de 2D \rightarrow 1D
- Objetivo: encontrar superfície de menor dimensão para projetar os dados de forma a minimizar o erro de projeção ortogonal




Análise de componentes principais: Ideia

- Reduzir de 2D \rightarrow 1D: encontrar direção (vetor $u^{(1)} \in \mathbb{R}^2$) para criar projeção que minimize o erro de projeção




Análise de componentes principais: Ideia




- Reduzir de 2D \rightarrow 1D: encontrar direção (vetor $u^{(1)} \in \mathbb{R}^2$) para criar projeção que minimize o erro de projeção

Análise de componentes principais: Ideia




- Reduzir de 2D \rightarrow 1D: encontrar direção (vetor $u^{(1)} \in \mathbb{R}^2$) para criar projeção que minimize o erro de projeção

Análise de componentes principais: Ideia



- Reduzir de 2D \rightarrow 1D: encontrar direção (vetor $u^{(1)} \in \mathbb{R}^2$) para criar projeção que minimize o erro de projeção

Análise de componentes principais: Ideia



- Reduzir de 2D \rightarrow 1D: encontrar direção (vetor $u^{(1)} \in \mathbb{R}^2$) para criar projeção que minimize o erro de projeção

Análise de componentes principais: Ideia

▪ Ideia geral

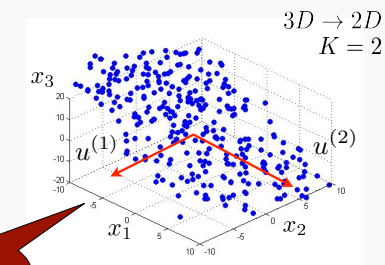
- Reduzir de $nD \rightarrow kD$: encontrar k vetores $u^{(1)}, u^{(2)}, \dots, u^{(k)}$ para criar projeção que minimize o erro de projeção

Análise de componentes principais: Ideia

▪ Ideia geral

- Reduzir de $nD \rightarrow kD$: encontrar k vetores $u^{(1)}, u^{(2)}, \dots, u^{(k)}$ para criar projeção que minimize o erro de projeção

▪ Exemplo




Direções

Análise de componentes principais: Ideia

▪ Ideia geral

- Reduzir de $nD \rightarrow kD$: encontrar k vetores $u^{(1)}, u^{(2)}, \dots, u^{(k)}$ para criar projeção que minimize o erro de projeção

▪ Exemplo

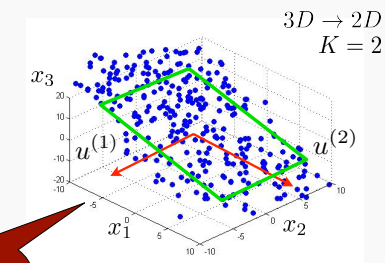


Análise de componentes principais: Ideia

▪ Ideia geral

- Reduzir de $nD \rightarrow kD$: encontrar k vetores $u^{(1)}, u^{(2)}, \dots, u^{(k)}$ para criar projeção que minimize o erro de projeção

▪ Exemplo



Superfície
de projeção

Análise de componentes principais: Etapa 1

■ Pré-processamento dos dados

- Seja a base de treinamento: $x^{(1)}, x^{(2)}, \dots, x^{(m)}$
- Aplicar normalização por padronização:

$$\mu_j = \frac{1}{m} \sum_{i=1}^m x_j^{(i)} \quad \sigma_j = \sqrt{\frac{1}{m-1} \sum_{i=1}^m (x_i - \mu_j)^2}$$

- Substituir cada $x_j^{(i)}$ por $x_j^{(i)} = \frac{x_j^{(i)} - \mu_j}{\sigma_j}$

Análise de componentes principais: Algoritmo

- Reduzir dimensionalidade de n para k
- Computar matriz de covariância Σ :

$$\Sigma = \frac{1}{m} \sum_{i=1}^m (x^{(i)})(x^{(i)})^T$$

- Computar autovetores de $\Sigma \in \mathbb{R}^{n \times n}$:

$$[U, S, V] = \text{svd}(\Sigma);$$

$U, S, V \in \mathbb{R}^{n \times n}$

Análise de componentes principais: Algoritmo

- $[U, S, V] = \text{svd}(\Sigma)$:

$$U = \begin{bmatrix} | & | & \dots & | \\ u^{(1)} & u^{(2)} & \dots & u^{(n)} \\ | & | & \dots & | \end{bmatrix} \in \mathbb{R}^{n \times n}$$

Direções

Análise de componentes principais: Algoritmo

- $[U, S, V] = \text{svd}(\Sigma)$:

$$U = \begin{bmatrix} | & | & \dots & | \\ u^{(1)} & u^{(2)} & \dots & u^{(n)} \\ | & | & \dots & | \end{bmatrix} \in \mathbb{R}^{n \times n}$$

Selecionar k
primeiras direções

$$U_r \in \mathbb{R}^{n \times k}$$

Análise de componentes principais: Algoritmo

- Tem-se que:

$$x \in \mathbb{R}^{n \times 1}$$
$$Ur \in \mathbb{R}^{n \times k}$$

Cada amostra do conjunto de treinamento

- Deseja-se:

$$x \in \mathbb{R}^{n \times 1} \rightarrow z \in \mathbb{R}^{k \times 1}$$

Análise de componentes principais: Algoritmo

- Tem-se que:

$$x \in \mathbb{R}^{n \times 1}$$
$$Ur \in \mathbb{R}^{n \times k}$$

k direções selecionadas

- Deseja-se:

$$x \in \mathbb{R}^{n \times 1} \rightarrow z \in \mathbb{R}^{k \times 1}$$

Análise de componentes principais: Algoritmo

- Tem-se que:

$$x \in \mathbb{R}^{n \times 1}$$
$$Ur \in \mathbb{R}^{n \times k}$$

Projeções de x em Ur

- Deseja-se:

$$x \in \mathbb{R}^{n \times 1} \rightarrow z \in \mathbb{R}^{k \times 1}$$

Análise de componentes principais: Algoritmo

- Tem-se que:

$$x \in \mathbb{R}^{n \times 1}$$
$$Ur \in \mathbb{R}^{n \times k}$$

Projeções de x em Ur

- Deseja-se:


$$x \in \mathbb{R}^{n \times 1} \rightarrow z \in \mathbb{R}^{k \times 1}$$

$$z = Ur^T x$$


Inteligência Artificial: Uma Abordagem de Aprendizado de Máquina

Análise de Componentes Principais Reconstrução


Análise de componentes principais: Reconstrução do dado




Análise de componentes principais: Reconstrução do dado



Análise de componentes principais: Reconstrução do dado



Análise de componentes principais: Reconstrução do dado



Deseja-se:
 $z \in \mathbb{R} \rightarrow x \in \mathbb{R}^2$

Como:
 $U \in \mathbb{R}^{n \times k}$
 $z \in \mathbb{R}^{k \times 1}$


Então:
 $x_{approx} = U \cdot z$

$$z = U^T x$$

Inteligência Artificial: Uma Abordagem de Aprendizado de Máquina

Análise de Componentes Principais Parâmetros

Análise de componentes principais: Reconstrução do dado



$$z = U^T x$$

$$x_{approx} = U \cdot z$$

Análise de componentes principais: Escolha de k

- k = número de dimensões de cada amostra (em PCA: quantidade de componentes principais)
- Como escolher um bom valor para k ?

Análise de componentes principais: Escolha de k

- EQM da projeção: $\frac{1}{m} \sum_{i=1}^m \|x^{(i)} - x_{approx}^{(i)}\|^2$
- Variância total dos dados: $\frac{1}{m} \sum_{i=1}^m \|x^{(i)}\|^2$
- Normalmente, k escolhido é o menor valor para

$$\frac{\frac{1}{m} \sum_{i=1}^m \|x^{(i)} - x_{approx}^{(i)}\|^2}{\frac{1}{m} \sum_{i=1}^m \|x^{(i)}\|^2} \leq 0.01 \quad (1\%)$$

99% da variância é mantida

Análise de componentes principais: Escolha de k

- Procedimento para escolha de k:
 - **Início**
 - Executar PCA com $k = 1$
 - Computar $U_r, z^{(1)}, z^{(2)}, \dots, z^{(m)}, x_{approx}^{(1)}, \dots, x_{approx}^{(m)}$
 - Checar se

$$\frac{\frac{1}{m} \sum_{i=1}^m \|x^{(i)} - x_{approx}^{(i)}\|^2}{\frac{1}{m} \sum_{i=1}^m \|x^{(i)}\|^2} \leq 0.01$$

- Caso contrário, $k = k + 1$ e volta para **início**

Análise de componentes principais: Escolha de k - SVD

- $[U, S, V] = \text{svd}(\text{Sigma})$
- **S**: matriz diagonal $n \times n$ com autovalores (S_{11}, S_{22}, S_{nn})

$$\frac{\frac{1}{m} \sum_{i=1}^m \|x^{(i)} - x_{approx}^{(i)}\|^2}{\frac{1}{m} \sum_{i=1}^m \|x^{(i)}\|^2} = 1 - \frac{\sum_{i=1}^k S_{ii}}{\sum_{i=1}^n S_{ii}} \leq 0.01$$

Análise de componentes principais: Escolha de k - SVD

- $[U, S, V] = \text{svd}(\text{Sigma})$
- **S**: matriz diagonal $n \times n$ com autovalores (S_{11}, S_{22}, S_{nn})
- Escolher menor k de tal forma que:

$$\frac{\sum_{i=1}^k S_{ii}}{\sum_{i=1}^n S_{ii}} \geq 0.99$$

Inteligência Artificial: Uma Abordagem de Aprendizado de Máquina

Análise de Componentes Principais Aplicação

Tiago A. Almeida

Análise de componentes principais: Aplicando PCA

- Seja o conjunto de treinamento $X \in \mathbb{R}^{10.000}$
 $(x^{(1)}, y^{(1)}), (x^{(2)}, y^{(2)}), \dots, (x^{(m)}, y^{(m)})$

Supor que $k=1000$ preserva
95% da variância dos dados

Tiago A. Almeida

Análise de componentes principais: Aplicando PCA

- Seja o conjunto de treinamento $X \in \mathbb{R}^{10.000}$
 $(x^{(1)}, y^{(1)}), (x^{(2)}, y^{(2)}), \dots, (x^{(m)}, y^{(m)})$

Tiago A. Almeida

Análise de componentes principais: Aplicando PCA

- Seja o conjunto de treinamento $X \in \mathbb{R}^{10.000}$
 $(x^{(1)}, y^{(1)}), (x^{(2)}, y^{(2)}), \dots, (x^{(m)}, y^{(m)})$

- Extrair apenas os atributos:

$$x^{(1)}, x^{(2)}, \dots, x^{(m)} \in \mathbb{R}^{10000}$$

Análise de componentes principais: Aplicando PCA

- Seja o conjunto de treinamento $X \in \mathbb{R}^{10.000}$
 $(x^{(1)}, y^{(1)}), (x^{(2)}, y^{(2)}), \dots, (x^{(m)}, y^{(m)})$

- Extraír apenas os atributos:

$$x^{(1)}, x^{(2)}, \dots, x^{(m)} \in \mathbb{R}^{10000}$$

$\downarrow PCA$

$$z^{(1)}, z^{(2)}, \dots, z^{(m)} \in \mathbb{R}^{1000}$$

Análise de componentes principais: Aplicando PCA

- Novo conjunto de treinamento $Z \in \mathbb{R}^{1000}$

$$(z^{(1)}, y^{(1)}), (z^{(2)}, y^{(2)}), \dots, (z^{(m)}, y^{(m)})$$

- Mapear amostras de teste $x^{(i)} \rightarrow z^{(i)}$ usando os parâmetros (U_r) encontrados na base de treinamento ($z = U_r^T \cdot x$) e computar $h(z)$

Análise de componentes principais: Aplicando PCA

- Novo conjunto de treinamento $Z \in \mathbb{R}^{1000}$

$$(z^{(1)}, y^{(1)}), (z^{(2)}, y^{(2)}), \dots, (z^{(m)}, y^{(m)})$$